

# GUÍA DE BUENAS PRÁCTICAS Y ARQUITECTURA

## ESTÁNDARES DE INGENIERÍA EN MACHINE LEARNING NO SUPERVISADO

El desarrollo de soluciones de Machine Learning (ML), especialmente en el ámbito del **aprendizaje no supervisado**, requiere un puente sólido entre el rigor matemático y los estándares de la ingeniería de software. A diferencia de los modelos supervisados, la ausencia de etiquetas de verdad de terreno incrementa la complejidad del preprocesamiento, el ajuste de hiperparámetros y la reproducibilidad técnica. Esta guía reúne la estructura organizacional y las mejores prácticas operativas basadas en el programa académico y los estándares del máster en Inteligencia Artificial.

### 1. Arquitectura de Directorio Estándar (Clean Layout)

Una estructura clara separa el código productivo de los experimentos rápidos y los datos crudos, garantizando la mantenibilidad del proyecto de acuerdo con los estándares modernos de Git:

```
mi-proyecto-ml/
├── README.md           # Documentación y guía de despliegue
├── requirements.txt     # Especificación estricta de dependencias
├── .gitignore          # Exclusión de archivos binarios, datos y temporales
├── kmeans_playground.py # Laboratorio interactivo y visualización rápida
├── git_refactor_radar.py # Script de auditoría de código
├── data/              # Aislamiento de datos (Nunca subir a Git)
│   ├── raw/          # Datos de origen (Ej. Customer_Data_Test.csv)
│   ├── processed/    # Matrices procesadas y guardadas
│   └── src/          # Código fuente modular
│       ├── __init__.py # Inicializador de paquete
│       ├── preprocesamiento.py # Módulos de limpieza y normalización
│       ├── modelado.py # Implementación de algoritmos de agrupación
│       └── visualizaciones.py # Generación automatizada de gráficos
├── outputs/          # Salidas y artefactos del modelo
│   ├── charts/       # Gráficos exportados (Elbow, Silhouette)
│   └── models/        # Parámetros del escalador y del modelo persistidos
```

**Regla de Oro en Producción:** Los archivos pesados de datos (.csv, .xlsx) y los entornos virtuales (.venv, .conda) NUNCA deben registrarse en el historial de Git. El archivo .gitignore debe configurarse preventivamente para bloquear la subida de datos crudos y optimizar el rendimiento del repositorio.

## 2. Preparación de Datos e Ingeniería de Características

La preparación de datos es fundamental porque los algoritmos numéricos de agrupamiento dependen completamente de la calidad y de la escala de la matriz de entrada. El flujo recomendado sigue tres pasos secuenciales rigurosamente fundamentados:

| Etapa del Proceso         | Acción Recomendada                                                                            | Justificación Científica                                                                                                  |
|---------------------------|-----------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------|
| Limpieza de Datos         | Eliminación de variables redundantes, duplicados y filas nulas usando Pandas.                 | Evita la colinealidad y evita que registros repetidos distorsionen los centroides del agrupamiento.                       |
| Tratamiento de Outliers   | Identificación de anomalías financieras o de comportamiento sin eliminarlas si aportan valor. | Permite segmentar de manera separada a los clientes de comportamiento extremo sin sesgar los grupos generales.            |
| Escalado con RobustScaler | Normalización usando la mediana y el rango intercuartílico (IQR) de scikit-learn.             | K-medias se basa en distancia euclídea. RobustScaler evita que variables con escalas masivas dominen y neutralicen otras. |

## 3. Heurísticas Matemáticas y Validación en K-medias

El algoritmo K-medias es altamente eficiente pero posee limitaciones críticas que deben ser mitigadas mediante el uso de métricas e inicializaciones inteligentes:

**A. Sensibilidad a la Inicialización:** El algoritmo estándar es sensible a la posición inicial de los centroides, pudiendo converger en óptimos locales deficientes. Se debe forzar el uso de **K-means++** (que distribuye los centroides de manera probabilísticamente separada al inicio) o bien evaluar la variante robusta **K-medoides**, que usa puntos de datos reales como centros para evitar la influencia directa de valores extremos de ruido.

**B. El Método del Codo (Elbow Technique):** Evalúa la suma de errores cuadráticos dentro de cada grupo (SSE) a través de distintos valores de K. Aunque busca el punto de inflexión o 'codo' de máxima eficiencia, no siempre es concluyente o fácil de detectar en datos reales ruidosos.

**C. El Análisis de Silueta:** Proporciona una validación más rigurosa al medir la similitud de un dato con su grupo frente a otros grupos. Su coeficiente oscila entre -1 y 1. Un valor promedio cercano a 1 indica una segmentación compacta y bien diferenciada espacialmente.

## 4. Interpretación de Modelos y Despliegue Técnico

Una vez que el modelo converge, la fase de interpretación es crucial para transformar vectores numéricos en decisiones tangibles. Esto se logra mediante tres aproximaciones complementarias:

- **Análisis de Centroides:** Mapear los centroides escalados de regreso a sus unidades originales para describir y caracterizar el 'perfil' promedio de cada segmento.
- **Perfilado Visual:** Generar diagramas de caja (boxplots) e histogramas para validar que cada variable tenga una distribución bien definida e independiente dentro de cada grupo.

- **Modelos Sustitutos (Surrogates):** Entrenar árboles de decisión rápidos usando los grupos creados por K-medias como etiquetas simuladas. Esto permite documentar de forma clara las reglas del modelo (e.g., 'Si la inestabilidad > 5, clasificar como Zona Caliente').

**Conclusión del Proceso:** Al integrar estas prácticas y estructurar modularmente tus programas, no solo generas modelos más robustos que evitan el sobreajuste y la inestabilidad del azar, sino que creas código reproducible, auditable y con nivel de producción listo para cualquier entorno de trabajo.